

Final Project: A Comparative Analysis of Machine Learning Architectures for Satellite-Based Surface Monitoring

Juan Pablo Flautero Contreras
Juan David Garrido Ramos
Andres Felipe Torres Monroy
Samuel Tovar Sarmiento

June 4, 2026

1 Introduction

In an era of unprecedented global change, modern geoinformatics has transitioned from traditional, static map-making to dynamic, real-time environmental monitoring. This project provides a comprehensive framework for students to apply the fundamentals of Geospatial Artificial Intelligence (GeoAI) to real-world scenarios, leveraging satellite imagery to quantify and analyze Earth surface covers. By integrating open-source tools with advanced machine learning architectures, students move beyond passive observation toward hands-on, structured spatial analysis. This pedagogical approach mirrors professional GeoAI applications, where model development and deployment occur within specialized computational frameworks independently of traditional GIS software. Through this workflow, participants will bridge the gap between raw spectral data and actionable environmental intelligence.

2 Possible Regions of Interest (ROI)

For this project, teams may choose to revisit the study areas analyzed in previous assignments. However, you are also free to select a new Region of Interest (ROI) from the curated list of case studies, such as Mocoa, Hunga Tonga, or the Kakhovka Dam, or propose a custom area that aligns with the project's objectives. You should pick just one image.

3 Supervised Classification and Spatial Prediction

In this phase, we move from basic image analysis to supervised machine learning. You will structure pixel-level information into training datasets, following a standard deployment workflow that operates independently of external GIS software. This approach mirrors real-world GeoAI applications where model development occurs in specialized computational frameworks.

3.1 Data Extraction and Table Construction

Students must transform the multi-spectral Sentinel bands into a non-spatial, tabular format suitable for machine learning training. Using a programming language of your choice,¹ you will develop scripts to read the satellite imagery and extract pixel values located within your training polygons. Each polygon serves as a ground-truth sample representing specific land cover classes within the scene, allowing you to build a structured dataset where each row corresponds to an individual pixel's spectral signature and its associated label.

¹Common choices include Python (e.g., using `rasterio` and `geopandas`) or R (e.g., using `terra` and `sf`).

- **Format:** Export data as a Tab-Separated Values (TSV) file.
- **Columns:** The table must include Latitude, Longitude, at least eight spectral bands (e.g., B2–B11), and a categorical class label (e.g., “Vegetation”, “Water”, “Bare soil”, etc).

3.2 Model Implementation and Training

Once the training dataset is prepared, students must implement and compare five distinct machine learning architectures. This comparative analysis is designed to evaluate how different mathematical approaches handle the high-dimensional spectral data of your selected scene. You will assess each model’s performance using standard validation metrics, including the Confusion Matrix, Kappa Coefficient, and F1-Score.

1. **Decision Trees (DT):** A logic-based model that utilizes a hierarchical tree structure to split data based on spectral thresholds. This approach is particularly useful for identifying which specific bands are most influential in distinguishing land cover classes.
2. **Support Vector Machines (SVM):** A kernel-based algorithm that identifies the optimal hyperplane to maximize the margin between class clusters in a multi-dimensional feature space. It is highly effective for complex classification tasks where classes are not linearly separable.
3. **Artificial Neural Networks (ANN):** A computational model composed of interconnected layers of neurons that learn complex, non-linear relationships between spectral signatures and land cover categories.
4. **K-Nearest Neighbor (KNN):** A non-parametric method that assigns a class membership based on a plurality vote of its neighbors. Pixels are classified according to the most common category among the “k” nearest training samples in the spectral feature space.
5. **Naive Bayes (NB):** A probabilistic classifier based on Bayes’ Theorem that assumes strong (naive) independence between the input spectral bands. It calculates the probability of each class given the observed pixel values and selects the most likely outcome.

3.3 Model Comparison and Performance Evaluation

To identify the most robust classification architecture, teams must perform an exhaustive Hyperparameter Optimization (HPO) process. This involves systematically testing and adjusting the internal settings of each algorithm to maximize its predictive power for your specific study area.

Once the models are tuned, you must conduct a rigorous performance assessment by comparing their resulting Confusion Matrices. Students are required to compute and analyze the following evaluation metrics:

- **Overall Accuracy:** To quantify the total percentage of correctly classified pixels.
- **Kappa Coefficient:** To measure the agreement between predicted and reference data beyond what is expected by chance.
- **Precision and Recall:** To assess the model’s reliability and completeness for each land-cover category.
- **F1-Score:** To determine the harmonic balance between precision and recall, ensuring the model remains accurate across all classes.

Finally, you must synthesize your findings into a comprehensive summary table. This table should facilitate a direct comparison between the five architectures, clearly highlighting the “best” performance based on the metrics listed above.

3.4 Final Raster Prediction (Inference)

The culmination of the classification pipeline is the generation of a comprehensive thematic land-cover map through full-scene inference. Once the optimal model has been identified and validated, having achieved the highest statistical performance in terms of F1-Score and Kappa Coefficient, it must be deployed to classify the remaining pixels that comprise the rest of the study area.

Unlike the training phase, which utilized a discrete Tab-Separated Values (TSV) dataset derived from specific polygons, the inference phase requires the model to process the original multidimensional raster stack. The model will iterate through each pixel, treating its eight or more spectral bands as input features to predict its most likely class membership. This process transforms raw reflectance data into a new, single-band categorical raster.

The output of this operation must be exported as a georeferenced GeoTIFF. In this final product, each pixel value corresponds to a specific integer code representing its predicted category (e.g., 1 for “Vegetation,” 2 for “Water”, 3 for “Bare soil” and so on). To ensure the result is of professional quality, students must address the following requirements:

- **Spatial Consistency:** The final raster must retain the original Coordinate Reference System (CRS) and affine transformation parameters. This ensures that the predictions align perfectly with the original satellite imagery and other geospatial layers.
- **Thematic Visualization:** Students must import the resulting GeoTIFF into a GIS environment (such as QGIS) and apply a discrete color symbology. This visualization should clearly distinguish between different land-cover types.
- **Area Quantification:** Beyond visual representation, you are required to generate spatial statistics. Use the predicted raster to calculate the total area (in hectares or square kilometers) for each class.

4 Project Phases and Weekly Deliverables

The project is divided into three milestones, each to be submitted at the end of its respective week:

Phase 1: Problem Definition (Week 1)

Focuses on event selection and data transformation.

- **Deliverables:** A document defining the chosen event, study area boundaries, satellite imagery metadata, and dataset creation.

Evento elegido

El evento seleccionado para el desarrollo del proyecto corresponde a los incendios forestales ocurridos en enero de 2025 en la ciudad de Los Ángeles, California, Estados Unidos, específicamente en las zonas afectadas por el incendio Palisades y sectores cercanos.

El objetivo del proyecto es aplicar técnicas de Machine Learning y GeoAI para realizar una clasificación supervisada de coberturas terrestres utilizando imágenes satelitales Sentinel-2. A partir de este análisis se busca identificar áreas quemadas, vegetación, zonas urbanas, cuerpos de agua y suelo desnudo dentro del área afectada por los incendios.



Figure 1: Área afectada por los incendios forestales en Los Ángeles, California.

Límites del área

El área de estudio (ROI) se localiza en el oeste de Los Ángeles, California, incluyendo sectores cercanos a Pacific Palisades, Malibu y Topanga.

La delimitación del área fue realizada en QGIS mediante un recorte rectangular aplicado sobre la imagen satelital multibanda, con el objetivo de reducir el tamaño de procesamiento y enfocar el análisis únicamente en las zonas afectadas por los incendios forestales.

Metadatos de la imagen satelital

La imagen utilizada corresponde a una adquisición Sentinel-2 Level-2A del 1 de febrero de 2025 obtenida del programa Copernicus.

Para el análisis se utilizaron ocho bandas espectrales correspondientes a B2, B3, B4, B5, B6, B7, B8 y B11. Las bandas B2, B3, B4 y B8 poseen resolución espacial de 10 metros, mientras que las bandas B5, B6, B7 y B11 originalmente poseen resolución de 20 metros, por lo que fueron remuestreadas a 10 metros mediante interpolación bilineal en QGIS para mantener consistencia espacial entre todas las bandas utilizadas.

Posteriormente, las bandas fueron integradas en un raster multibanda mediante un Virtual Raster (VRT), el cual fue recortado al área de estudio y utilizado para la extracción de información espectral y generación del dataset.

Parámetro	Valor
Satélite	Sentinel-2
Fecha de adquisición	2025-02-01
Nivel de procesamiento	Level-2A
Resolución espacial	10 m
Bandas utilizadas	B2, B3, B4, B5, B6, B7, B8, B11
Composición RGB	4-3-2
False Color	8-4-3

Table 1: Metadatos de la imagen satelital utilizada.

Creación del dataset

La construcción del dataset se realizó en QGIS a partir de la imagen multibanda Sentinel-2 y muestras de entrenamiento creadas manualmente sobre el área de estudio.

Inicialmente, se creó una capa vectorial tipo shapefile denominada `training_samples.shp`, utilizada para almacenar polígonos representativos de las diferentes clases de cobertura terrestre presentes en la imagen.

Las clases utilizadas fueron:

- Burned
- Land
- Urban
- Vegetation
- Water

Cada polígono fue dibujado manualmente sobre zonas homogéneas utilizando herramientas de digitalización de QGIS. Posteriormente, mediante la herramienta **Puntos aleatorios en polígonos**, se generaron puntos aleatorios dentro de cada muestra de entrenamiento. Se hicieron 10 polígonos por clase y en cada uno de ellos se encontraron 150 puntos aleatorios

Clase	Número de muestras
Burned	1500
Land	1500
Urban	1500
Vegetation	1500
Water	1500
Total	7500

Table 2: Distribución de muestras utilizadas para el entrenamiento.



Figure 2: Distribución de los polígonos en la zona.

Luego, usando la herramienta **Muestrear valores raster**, se extrajeron automáticamente los valores espectrales correspondientes a las ocho bandas del raster multibanda `sentinel_stack_crop.tif` para cada punto generado.

El resultado fue una nueva capa con información espectral y etiquetas de clase para cada muestra de entrenamiento. Posteriormente, se añadieron las coordenadas X/Y mediante la calculadora de campos y el dataset fue exportado en formato TSV (Tab-Separated Values).

La estructura final del dataset corresponde a:

	class	BAND_1	BAND_2	BAND_3	BAND_4	...
	Water	1033	1020	1029	1009	...
...	BAND_5	BAND_6	BAND_7	BAND_8	X	Y
...	1183	1127	1045	1021	341086.850	3765529.344

Table 3: Estructura del dataset generado en QGIS.

Donde:

- BAND_1 corresponde a la banda B2
- BAND_2 corresponde a la banda B3
- BAND_3 corresponde a la banda B4
- BAND_4 corresponde a la banda B5
- BAND_5 corresponde a la banda B6
- BAND_6 corresponde a la banda B7
- BAND_7 corresponde a la banda B8
- BAND_8 corresponde a la banda B11

Este dataset será utilizado posteriormente para el entrenamiento y evaluación de los modelos de Machine Learning del proyecto.

Phase 2: Pre-processing and Training (Week 2)

Focuses on technical preparation and initial model testing.

- **Deliverables:** Documentation of the exported TSV training file, and initial model evaluation metrics (at least Confusion Matrix and Overall Accuracy).

Preprocesamiento del dataset

El entrenamiento de los modelos fue desarrollado utilizando Python y la librería **scikit-learn** en Visual Studio Code. El dataset generado en QGIS fue exportado en formato CSV y posteriormente cargado para realizar el preprocesamiento y entrenamiento de los modelos de clasificación supervisada.

Inicialmente, se importó el dataset utilizando la librería **pandas**, separando las variables espectrales correspondientes a las ocho bandas Sentinel-2 y las etiquetas de clase.

La columna **class** fue utilizada como variable objetivo para el entrenamiento de los modelos.

Posteriormente, se realizó una normalización de los datos mediante **StandardScaler**, transformando cada variable para que presentara media igual a cero y desviación estándar igual a uno. Este proceso resulta especialmente importante para algoritmos basados en distancias o en optimización numérica, como SVM, KNN y ANN.

Finalmente, el conjunto de datos fue dividido mediante la función **train_test_split**, utilizando un 70% de las muestras para entrenamiento y un 30% para validación. Adicionalmente, se utilizó el parámetro **stratify** para conservar la proporción original de cada clase en ambos subconjuntos, garantizando una evaluación representativa del desempeño de los modelos.

Implementación de modelos

Se implementaron cinco arquitecturas de Machine Learning utilizando la librería `scikit-learn`. Con el objetivo de mejorar la capacidad predictiva de los modelos, se realizó un ajuste manual de hiperparámetros. Los hiperparámetros corresponden a configuraciones internas definidas antes del entrenamiento y que controlan el comportamiento del algoritmo durante el proceso de aprendizaje.

Los resultados obtenidos fueron comparados mediante Accuracy, Kappa Coefficient, Precision, Recall, F1-Score y matrices de confusión.

Decision Tree (DT)

El árbol de decisión fue configurado mediante los siguientes hiperparámetros:

- `max_depth = 15`: limita la profundidad máxima del árbol para evitar sobreajuste y permitir una mejor generalización.
- `min_samples_split = 5`: exige al menos cinco muestras para realizar una nueva división de un nodo, reduciendo divisiones innecesarias.
- `min_samples_leaf = 2`: obliga a que cada nodo terminal contenga como mínimo dos muestras, disminuyendo la sensibilidad al ruido.
- `random_state = 42`: garantiza la reproducibilidad de los resultados.

Estos parámetros permitieron generar árboles más estables y menos propensos al sobreajuste en comparación con la configuración por defecto del algoritmo.




Figure 3: Matriz de confusión del modelo Decision Tree.

Support Vector Machine (SVM)

El modelo SVM fue implementado utilizando los siguientes hiperparámetros:

- **kernel = rbf**: utiliza una función de base radial (Radial Basis Function) que permite modelar relaciones no lineales entre las clases y generar fronteras de decisión más complejas.
- **C = 10**: controla la penalización aplicada a los errores de clasificación. Un valor mayor obliga al modelo a reducir los errores sobre los datos de entrenamiento, generando fronteras más precisas.
- **gamma = scale**: ajusta automáticamente el alcance de influencia de cada muestra utilizando la varianza de los datos de entrada, facilitando una mejor adaptación al conjunto de entrenamiento.
- **probability = False**: desactiva el cálculo de probabilidades de pertenencia a cada clase. Esta configuración reduce el tiempo de entrenamiento y consumo computacional, ya que para este proyecto únicamente se requerían las clases predichas y no estimaciones probabilísticas.

La combinación de estos parámetros permitió una mejor separación entre coberturas espectralmente similares, obteniendo un desempeño superior respecto a la configuración básica del modelo.




Figure 4: Matriz de confusión del modelo SVM.

Artificial Neural Network (ANN)

La red neuronal artificial fue una de las arquitecturas con mejor desempeño en la clasificación supervisada de coberturas terrestres. Este modelo permite aprender relaciones altamente no lineales entre las bandas espectrales Sentinel-2 y las clases de cobertura mediante múltiples capas de procesamiento.

Los hiperparámetros utilizados fueron:

- **hidden_layer_sizes=(150,100,50)**: define tres capas ocultas con 150, 100 y 50 neuronas respectivamente. Esta estructura profunda permite aprender patrones espectrales complejos y construir representaciones jerárquicas de los datos.

- **activation='relu'**: utiliza la función de activación ReLU (Rectified Linear Unit), la cual introduce no linealidad en la red y facilita el aprendizaje de relaciones complejas entre variables espectrales.
- **solver='adam'**: emplea el optimizador Adam, un método de descenso de gradiente adaptativo que ajusta automáticamente los pesos de la red durante el entrenamiento y acelera la convergencia.
- **alpha=0.0001**: parámetro de regularización L2 utilizado para reducir el sobreajuste, penalizando pesos excesivamente grandes dentro de la red neuronal.
- **learning_rate='adaptive'**: permite disminuir automáticamente la tasa de aprendizaje cuando las mejoras en el entrenamiento comienzan a estabilizarse, favoreciendo una convergencia más precisa.
- **max_iter=2000**: establece un máximo de 2000 iteraciones de entrenamiento, proporcionando suficiente tiempo para que la red ajuste adecuadamente sus parámetros y alcance una solución estable.
- **random_state=42**: garantiza la reproducibilidad de los resultados obtenidos.

En comparación con la configuración inicial utilizada durante las primeras pruebas, que consistía en una sola capa oculta de 100 neuronas y un máximo de 500 iteraciones, la arquitectura final incrementó considerablemente la capacidad de aprendizaje del modelo. La incorporación de tres capas ocultas permitió capturar relaciones espectrales más complejas entre las coberturas terrestres, mientras que el aumento del número máximo de iteraciones favoreció una convergencia más completa del proceso de entrenamiento.

Estas mejoras permitieron una mejor diferenciación entre clases con firmas espectrales similares, especialmente entre vegetación, áreas quemadas y suelo desnudo, reduciendo errores de clasificación y mejorando las métricas globales de desempeño respecto a la configuración inicial.




Figure 5: Matriz de confusión del modelo Artificial Neural Network.

K-Nearest Neighbor (KNN)

El clasificador KNN fue configurado con los siguientes hiperparámetros:

- `n_neighbors = 7`: utiliza siete vecinos para determinar la clase predominante.
- `weights = distance`: asigna mayor importancia a los vecinos más cercanos.
- `metric = minkowski`: emplea la familia de distancias Minkowski.
- `p = 2`: corresponde específicamente a la distancia euclidiana.

Esta configuración permitió una clasificación más robusta frente a valores atípicos y redujo errores ocasionados por muestras aisladas.




Figure 6: Matriz de confusión del modelo KNN.

Naive Bayes (NB)

El clasificador probabilístico Naive Bayes fue implementado utilizando:

- `var_smoothing = 1e-8`: agrega una pequeña constante a la varianza para mejorar la estabilidad numérica y evitar divisiones por valores extremadamente pequeños.

Aunque este ajuste mejoró ligeramente el desempeño respecto a la configuración predeterminada, el modelo continuó presentando limitaciones debido a la hipótesis de independencia entre bandas espectrales, condición que rara vez se cumple completamente en imágenes multiespectrales Sentinel-2.




Figure 7: Matriz de confusión del modelo Naive Bayes.

Impacto del ajuste de hiperparámetros

La optimización de hiperparámetros permitió mejorar la capacidad de generalización de los modelos y reducir errores de clasificación observados en las matrices de confusión iniciales.

Los principales beneficios obtenidos fueron:

- Reducción del sobreajuste en Decision Tree mediante restricciones adicionales en la estructura del árbol.
- Mejor separación de clases en SVM gracias al incremento del parámetro C .
- Mayor capacidad de aprendizaje no lineal en ANN mediante una arquitectura más profunda y un mayor número de iteraciones.
- Clasificaciones más estables en KNN mediante el uso de ponderación por distancia.
- Mayor estabilidad numérica en Naive Bayes mediante el ajuste de `var_smoothing`.

En términos generales, los modelos optimizados obtuvieron métricas superiores a las alcanzadas con los parámetros predeterminados de `scikit-learn`, evidenciando la importancia del ajuste de hiperparámetros en problemas de clasificación de imágenes satelitales.

Resultados obtenidos

Los resultados obtenidos muestran un alto desempeño general en la clasificación supervisada de coberturas terrestres utilizando información espectral Sentinel-2.

El modelo con mejor desempeño fue Artificial Neural Network (ANN), obteniendo los mayores valores.

Modelo	Accuracy	Kappa	Precision	Recall	F1-Score
Decision Tree	0.9827	0.9783	0.9830	0.9827	0.9827
SVM	0.9836	0.9794	0.9843	0.9836	0.9836
ANN	0.9898	0.9872	0.9898	0.9898	0.9898
KNN	0.9893	0.9867	0.9894	0.9893	0.9893
Naive Bayes	0.9102	0.8878	0.9123	0.9102	0.9102

Table 4: Comparación de desempeño de los modelos de Machine Learning.

Los resultados evidencian que los modelos basados en aprendizaje no lineal, especialmente ANN, presentan una mayor capacidad para diferenciar coberturas complejas como áreas urbanas, vegetación y superficies quemadas utilizando información espectral multibanda.

Por otro lado, Naive Bayes presentó el menor desempeño debido a la suposición de independencia entre variables espectrales, condición que no se cumple completamente en imágenes multiespectrales Sentinel-2.

Debido a que ANN presentó simultáneamente los mayores valores de Accuracy, Kappa, Precision, Recall y F1-Score, fue seleccionado para la clasificación completa de la imagen.

Phase 3: Synthesis and Prediction (Week 3)

Una vez finalizada la etapa de entrenamiento y evaluación de los modelos de clasificación supervisada, se seleccionó el modelo con mejor desempeño para realizar la clasificación de la imagen completa. La selección se realizó con base en las métricas de Accuracy, Kappa, Precision, Recall y F1-Score obtenidas durante la fase de validación.

Los resultados mostraron que la Red Neuronal Artificial (ANN) obtuvo el mejor desempeño global, alcanzando una exactitud del 98.98%, un coeficiente Kappa de 0.9872 y valores superiores al 98.9% en Precision, Recall y F1-Score. Debido a este comportamiento, el modelo ANN fue seleccionado para generar el mapa temático final del área de estudio.

Posteriormente, el modelo entrenado y el escalador de datos fueron almacenados mediante la librería `joblib`. Estos elementos fueron utilizados para realizar la predicción píxel a píxel sobre la imagen multiespectral `sentinel_stack_crop.tif`. Para ello, las ocho bandas espectrales fueron reorganizadas en una matriz de características, normalizadas utilizando el mismo `StandardScaler` empleado durante el entrenamiento y finalmente clasificadas mediante el modelo ANN.

El resultado del proceso fue un raster temático denominado `final_classification.tif`, en el cual cada píxel fue asignado a una de las coberturas terrestres definidas durante la etapa de entrenamiento. El archivo fue exportado en formato GeoTIFF conservando el sistema de referencia espacial, la resolución espacial y la extensión geográfica de la imagen original.

La visualización del raster clasificado fue realizada en QGIS mediante una simbología categórica, asignando colores específicos a cada cobertura identificada. Esto permitió generar un mapa temático de fácil interpretación y evaluar visualmente la distribución espacial de las diferentes clases presentes dentro del área de estudio.



Figure 8: Mapa temático generado a partir de la clasificación supervisada utilizando el modelo ANN.

Los resultados obtenidos evidencian que las firmas espectrales extraídas durante el proceso de muestreo fueron suficientemente representativas para diferenciar las coberturas analizadas. Asimismo, la optimización de hiperparámetros contribuyó a mejorar la capacidad de generalización de los modelos, permitiendo alcanzar niveles de precisión superiores al 98%.

Cuantificación de áreas

Con el fin de complementar el análisis espacial, se realizó la cuantificación de áreas para cada cobertura terrestre identificada en el raster clasificado. Para ello, se contabilizó el número de píxeles pertenecientes a cada clase y posteriormente se calculó el área correspondiente.

Dado que la imagen Sentinel-2 utilizada posee una resolución espacial de 10 m, cada píxel representa una superficie de 100 m², equivalente a 0.01 hectáreas. A partir de esta relación fue posible estimar el área ocupada por cada cobertura dentro del área de estudio.

Clase	Píxeles	Área (ha)	Área (km ²)
Burned	224863	2248.63	22.49
Land	1436287	14362.87	143.63
Urban	487182	4871.82	48.72
Vegetation	26678	266.78	2.67
Water	686887	6868.87	68.69
Total	2861897	28618.97	286.19

Table 5: Distribución espacial de coberturas obtenidas mediante la clasificación supervisada.

5 Conclusion

El presente proyecto permitió desarrollar un flujo de trabajo completo de teledetección y aprendizaje automático para la clasificación supervisada de coberturas terrestres utilizando imágenes Sentinel-2. A partir de la extracción de firmas espectrales en QGIS, se construyó un conjunto de datos multiespectral que posteriormente fue utilizado para entrenar y evaluar diferentes algoritmos de Machine Learning.

Los resultados obtenidos demostraron que la Red Neuronal Artificial (ANN) fue el modelo con mejor desempeño, alcanzando una exactitud del 98.98%, un coeficiente Kappa de 0.9872 y valores superiores al 98.9% en Precision, Recall y F1-Score. Estos indicadores evidencian una alta capacidad de clasificación y una excelente concordancia entre las predicciones realizadas y las clases reales utilizadas durante la validación.

La implementación de técnicas de normalización y optimización de hiperparámetros permitió mejorar significativamente el rendimiento de los modelos, reduciendo errores de clasificación y aumentando la capacidad de generalización sobre datos no observados durante el entrenamiento.

Finalmente, la generación del raster temático `final_classification.tif` permitió transformar información espectral multibanda en un producto cartográfico interpretable, facilitando el análisis espacial de las coberturas presentes en el área de estudio. De esta manera, se cumplieron satisfactoriamente los objetivos planteados para el proyecto, integrando herramientas de Sistemas de Información Geográfica, procesamiento digital de imágenes y aprendizaje automático dentro de un mismo flujo metodológico.